Tópicos em IA / PLN: Criação de LLMs do Zero
Atividade Prática 2

1. Implementar as quatro estratégias do mecanismo de atenção de um LLM:
   i) *Self-attention* sem pesos treináveis
   ii) *Self-attention* com pesos treináveis (uso das matrizes de pesos query (W_q), key (W_k) e value (W_v)
   iii) *Causal attention (masked attention)*, usando também *dropout mask*.
   iv) Multi-head attention
2. Implementar o bloco *Transformer*, usado em vários LLMs. Lembrar que ele combina diversos conceitos: *masked multi-head attention*, camada de normalização, *dropout*, camadas *feed forward* e funções de ativação *GeLU*.
3. Implementar uma função para codificar um modelo *GPT-like*. Fazer métodos para carregar os pesos no modelo criado. (Alerta: verificar se a topologia criada é a mesma do modelo com os pesos baixados).
4. Criar uma função para calcular os requisitos de memória necessários para armazenar os parâmetros do modelo criado. (sugestão: usar o método *.numel()* para calcular o número de parâmetros do modelo criado). Usar a função para verificar a quantidade de memória (em MB) usada por alguns modelos de LLMs, incluindo os da família GPT. Obs: lembrar que o modelo GPT-2 original usou o conceito *weight* tying (emparelhamento de pesos) para reusar os pesos da camada de *embeddings* na camada de saída. Portanto, esses pesos devem ser reduzidos do número total retornado pelo método *.numel()*.
5. Preparar dados textuais em português para pré-treinar um modelo baseado no gpt-2. Criar o *dataset* e o *dataloader*, usando janela de contexto de tamanho 256 *(max_length=256)*, deslocamento de 128 *(stride=128)*, lotes de tamanho 4 ou mais *(batch_size=4)*, embaralhamento dos tensores e *dropout* de 20%.
6. Pré-treinar o modelo por 3 épocas *(epoch=3)*. Analisar se o modelo melhora a qualidade das respostas para perguntas gerais baseadas nos dados de treinamento. (sugestão: avaliar pelo menos cinco perguntas).